Avaluació final per passar a projecte

Título:

Detección automática de noticias falsas en el contexto colombiano 2022-2023 con Machine Learning y Bidirectional Encoder Representations from Transformers (BERT)

Introducción

Este proyecto pretende realizar una exploración inicial de las técnicas de machine learning y BERT utilizadas para detectar de manera automática noticias falsas.

Parte de la constatación de los efectos cada vez más negativos de la desinformación masiva sobre el desarrollo armónico de la humanidad y la necesidad de buscar maneras efectivas para combatirla.

No obstante, en este ejercicio no realizaremos ningún tipo de disertación teórica sobre las noticias falsas y la desinformación, sino que nos centraremos en intentar probar los métodos de machine learning y BERT que han sido utilizados para detectar este tipo de noticias.

Por dicha razón no comenzaremos este proyecto de cero, sino que será la continuación y ampliación de los resultados obtenidos en la tesis de grado de la Universidad ICESI "Modelo para la detección de noticias falsas en formato texto en la red social Twitter, aplicado al contexto político colombiano de las elecciones presidenciales de 2022" escrita por Jesús Flores y Juan Montaño.

Dichos autores utilizaron un dataframe compuesto por 634 noticias (317 falsas y 317 verdaderas) obtenidas de periódicos y páginas de verificación de noticias falsas colombianas durante el año 2022.

Sobre este dataframe, Flores y Montaño probaron los modelos Random Forest, Naive Bayes, Regresión Logística, SVM, XGBoost, Redes Neuronales y BERT. Lo hicieron sobre su dataset inicial y luego ampliaron su dataset utilizando el corpus de Posadas-Durán, 2019 (contexto mexicano) y el de Arsenii Tretiakov, 2020 (otros contextos).

Nosotros decidimos ampliar el dataset de Flores y Montaño con un corpus construido manualmente con 407 noticias falsas obtenidas del sitio de verificación ColombiaCheck y 407 noticias verdaderas colombianas obtenidas del periódico El Espectador, publicadas ambas durante el año 2023

Objetivos:

Dadas estas condiciones, el objetivo general de este proyecto es:

- Ampliar la base de datos de Flores y Montaño y determinar si los resultados varían

Para tal fin utilizaremos los siguientes modelos:

- Random Forest,
- Regresión Logística
- XGBoost
- SVM
- BERT

En cuanto al modelo BERT utilizaremos su versión en español y determinaremos si los resultados cambian.

Finalmente, utilizaremos los modelos mejor puntuados para comprobar cómo podrían detectar si una noticia es o no falsa utilizando noticias nuevas que no hicieron parte del modelado.

En síntesis, el índice del proyecto sería:

- Carga de librerías
- Importación de datasets
- Concatenación de dataset
- Limpieza de datasets
- Preprocesamiento (tokenización, stopwords, lemantización, stemeed, etc)
- Descripción del dataset preprocesado (nube de palabras y promedio de carácteres)
- Vectorización del dataset
- Modelaje
- Evaluación y Resultados
- Comparación entre los resultados del dataset original y del dataset ampliado
- Detección de noticias falsas y verdaderas utilizando los dos modelos mejor puntuados.

Dataset

Haciendo una revisión de la literatura sobre detección de noticias falsas con ML hemos detectado que la mayoría de datasets están compuestos por las siguientes columnas:

- ID: Consecutivo identificativo de cada row
- Fecha de la noticia: fecha de publicación de la noticia
- Fuente: Medio de comunicación de donde se extrajo la noticia
- Categoría: Tema sobre el cual habla la noticia
- Titular: Titular de la noticiaTexto: Cuerpo de la noticia
- Clase: Binario (1/0 = Noticia falsa / Noticia verdadera)
- URL: vínculo de la noticia

Sin embargo, para poder concatenar la base de datos ampliada con la original utilizaremos su misma estructura. Es decir:

- ID
- Categoría: Noticia Falsa / Noticia verdadera
- Tema: Tema del que trata la noticia
- Origen: Medio de comunicación de donde se extrajo la noticia
- Título: Titular
- Texto: Cuerpo de la noticia (en este caso el título está incluido dentro del texto)
- Fuente: URL

Bibliografía:

 Flores, Jesús Eduardo y Montaño, Juan Gabriel. Modelo para la detección de noticias falsas en formato texto en la red social Twitter, aplicado al contexto político colombiano de las elecciones presidenciales de 2022. Proyecto de Grado. Facultad de Ingeniería. Maestría en Ciencia de Datos. Universidad ICESI, 2022.